

Relatório técnico — Tech Challenge IADT Fase 1

Tema: sistema inteligente de suporte ao diagnóstico e detecção de riscos em saúde da mulher

Recorte desta fase: classificação de câncer de mama (maligno vs. benigno) com Machine Learning tabular

Dataset: Breast Cancer Wisconsin Diagnostic (UCI), equivalente ao conjunto sugerido no Kaggle (<https://www.kaggle.com/datasets/uciml/breast-cancer-wisconsin-data/data>)

Repositório Git: *(inserir URL após o push)*

Repositório Git: *(inserir URL após o push)*

1. Problema e objetivo

Uma rede de hospitais e centros especializados no atendimento à mulher precisa acelerar a triagem de risco. O enunciado da Fase 1 pede a base de um sistema de IA com foco em Machine Learning: analisar dados médicos automaticamente para identificar padrões relacionados à segurança e à saúde feminina.

Escolhemos o diagnóstico de câncer de mama a partir de 30 atributos numéricos extraídos de imagens digitais de núcleos celulares no exame FNA (*fine needle aspirate*). A tarefa é binária:

Classe | Código usado no projeto | Significado clínico

Positiva | 1 | Maligno

Negativa | 0 | Benigno

O sistema não emite diagnóstico final. Ele calcula uma probabilidade e uma explicação (SHAP) para apoiar o profissional. A palavra final é sempre do médico.

O enunciado também cita sinais de violência doméstica em prontuários. Esse recorte exigiria NLP sobre texto clínico e ficou fora do escopo da Fase 1, que prioriza classificação tabular bem documentada, métricas e explicabilidade.

2. Dados

2.1 Fonte


- Carregamento reprodutível: `sklearn.datasets.load_breast_cancer`
- Mesma origem UCI do CSV do Kaggle (colunas id / Unnamed: 32 do Kaggle não entram, pois o sklearn já entrega só as 30 features clínicas)
- 569 amostras, 30 features contínuas, 0 valores ausentes na versão sklearn

As features descrevem estatísticas mean, error (desvio padrão) e worst (média dos três maiores valores) de dez medidas nucleares: raio, textura, perímetro, área, suavidade, compactidade, concavidade, pontos côncavos, simetria e dimensão fractal.

O rótulo original do sklearn é invertido em relação à intuição clínica (0 = malignant). Remapeamos para 1 = maligno, de modo que recall/F1 da classe positiva correspondam ao risco que queremos detectar.

2.2 Visão geral

- Benignos: 357 (~62,7%)
- Malignos: 212 (~37,3%)
- Desbalanceamento moderado — accuracy sozinha mascara erros na classe rara/crítica




Balanceamento das classes

3. Exploração de dados (EDA)

3.1 Estatísticas descritivas e padrões clínicos


Tumores malignos tendem a apresentar maior raio, perímetro, área e concavidade. Isso é coerente com a literatura do FNA: núcleos maiores e mais irregulares associam-se a malignidade.



Boxplots das features clínicas

As distribuições condicionais mostram sobreposição (nem todo núcleo grande é maligno), mas a massa de probabilidade do grupo maligno desloca-se à direita em `mean_radius`, `mean_concave_points`, `worst_area` e `worst_concave_points`.

Distribuições condicionais ao diagnóstico




Histogramas das features-chave


3.2 Correlação e colinearidade

Raio, perímetro e área são quase colineares ($\text{perímetro} \approx 2\pi r$ e $\text{área} \approx \pi r^2$ em núcleos aproximadamente circulares). O mesmo vale para as versões *worst*.


Correlação entre features clínicas (recortes mean/worst)



Correlação entre features clínicas



Matriz de correlação completa



Scatter raio médio vs. pior raio

Decisão: manter as 30 features originais. O enunciado pede pipeline de pré-processamento e análise de correlação, não necessariamente redução dimensional. Regularização L2 na logística e o ensemble do Random Forest lidam com colinearidade de forma aceitável neste tamanho de amostra. PCA ficou como melhoria futura, não como etapa obrigatória.

4. Pré-processamento

Estratégia implementada em `src/preprocess.py`, sempre dentro de um `sklearn.Pipeline`, para não vazar estatísticas do teste:

- Limpeza: na versão `sklearn` não há missing. Ainda assim usamos `SimpleImputer(strategy="median")` para documentar o tratamento exigido e para tolerar o CSV do Kaggle (que traz coluna vazia `Unnamed: 32`).
- Tipos: todas as features já são numéricas contínuas; o alvo foi binarizado (`maligno = 1`).
- Escala: `StandardScaler`. Obrigatório para KNN (distância euclidiana) e recomendado para regressão logística. Árvores não precisam de escala, mas o mesmo pré-processamento deixa a comparação justa.
- Split: `train_test_split(test_size=0.20, stratify=y, random_state=42)` — 80/20 com a mesma proporção maligno/benigno nos dois conjuntos.

Não houve encoding categórico. Não removemos outliers agressivamente: valores extremos de

área/raio são sinal clínico, não necessariamente erro de digitação.

5. Modelagem

Treinamos três classificadores com GridSearchCV (5 folds estratificados) otimizando recall da classe positiva:

Modelo | Motivação | Hiperparâmetros buscados

Regressão logística | Baseline clínico, coeficientes interpretáveis, class_weight="balanced" | $C \in \{0.1, 1, 10\}$

Random Forest | Relações não lineares + importância nativa de features | n_estimators, max_depth, min_samples_split

KNN | Terceiro algoritmo simples e didático; muito sensível à escala | n_neighbors, weights

O modelo de produção da demo é o de maior recall maligno no teste, com desempate em F1 e ROC-AUC (src/train.py).

6. Treinamento, métricas e interpretação

6.1 Por que essas métricas?

No câncer, falso negativo (maligno predito como benigno) atrasa biópsia e tratamento. Por isso:

1. Recall maligno — métrica principal (sensibilidade)
2. F1 maligno — equilíbrio com precisão (falsos positivos geram ansiedade e exames extras, mas o custo é menor que o FN)
3. Matriz de confusão — deixa FN/FP explícitos
4. Accuracy — reportada com crítica (classe majoritária benigna)
5. ROC-AUC / PR-AUC — qualidade do ranking das probabilidades

Resultados no conjunto de teste (split 80/20 estratificado, random_state=42):

Modelo | Accuracy | Recall maligno | Precision maligno | F1 maligno | ROC-AUC


Regressão logística | 0.974 | 0.952 | 0.976 | 0.964 | 0.995

Random Forest | 0.974 | 0.929 | 1.000 | 0.963 | 0.998


KNN | 0.939 | 0.857 | 0.973 | 0.911 | 0.983

A regressão logística foi escolhida para a demo: maior recall da classe maligna (métrica principal). O Random Forest empata em accuracy e tem ROC-AUC ligeiramente maior, mas deixa passar mais falsos negativos. O KNN fica atrás, como esperado em um espaço com colinearidade.

Hiperparâmetros via GridSearchCV (5 folds, scoring = recall): logística C=1.0; RF n_estimators=250, max_depth=8; KNN k=3, weights=uniform.




Comparação de métricas




Curvas ROC

Matriz de confusão — Regressão logística




Matriz — regressão logística

Matriz de confusão — Random Forest



Matriz — Random Forest



Matriz — KNN

Os números exatos da última execução estão em `models/metrics.json` e `models/metrics_table.csv`. O app Streamlit e `python -m src.train` exibem a tabela atualizada.

6.2 Leitura crítica dos resultados

Espera-se accuracy e ROC-AUC altos neste dataset clássico — ele é relativamente linearmente separável. Isso não significa prontidão clínica:

- Uma única origem (Wisconsin), ~569 casos, sem validação temporal nem multicêntrica
- Features de laboratório já “limpas”, muito diferentes de um prontuário real
- Risco de superestimar generalização (mesmo com split estratificado e CV)


Um modelo utilizável na triagem deveria ser calibrado no hospital de destino, monitorado para *drift* e sempre revisado por um médico.

7. Explicabilidade

7.1 Feature importance


- Random Forest: impureza (Gini) — em geral destacam `worst_concave_points`, `worst_area`, `mean_concave_points`, `worst_radius`
- Regressão logística: valor absoluto dos coeficientes após o `StandardScaler` (comparáveis

entre si)



Importância — regressão logística

Importância das features — Random Fore




Importância — Random Forest

7.2 SHAP

Usamos SHAP no modelo interpretável selecionado (árvore ou logística; se o melhor for KNN, o SHAP recai no Random Forest).


- Global (beeswarm): quais features mais empurram a predição para maligno no conjunto de teste
- Local (waterfall): um caso maligno e um benigno, úteis na demo e no vídeo

SHAP global — Regressão logística (classe maligno)




SHAP global

SHAP local — Regressão logísticacaso maligno



SHAP local — caso maligno

SHAP local — Regressão logística caso benigno



SHAP local — caso benigno

Nesta execução o melhor modelo (e o usado no SHAP) foi a regressão logística. Se uma nova rodada escolher o Random Forest, os arquivos terão o prefixo shap_*_random_forest.png.

Interpretação para o clínico: barras que aumentam o valor SHAP elevam a probabilidade de maligno. O waterfall parte do valor base (média do modelo) e soma as contribuições até a predição do caso.

8. Uso prático e ética

Pode ser usado na prática? Como apoio à triagem / segunda opinião quantitativa, em ambiente controlado, sim. Como diagnóstico automático, não.

Como usaria um hospital, em tese:

- Laboratório informa as 30 medidas do FNA
- O sistema devolve probabilidade de malignidade + SHAP local
- O médico cruza com exame físico, imagem e biópsia
- Casos de alta probabilidade sobem na fila de revisão

Salvaguardas:

- Disclaimer visível no app
- Médico no loop (human-in-the-loop)

- Sem dados pessoais no repositório (dataset público e anônimo)
- Sem pretensão de cobrir violência doméstica nesta fase
- CNN em mamografia (EXTRA do enunciado) ficou de fora, para concentrar a entrega no pipeline tabular

9. Organização do código

Caminho | Papel

src/data.py | Carga Wisconsin + split estratificado

src/preprocess.py | Pipeline imputer + scaler

src/eda.py | Figuras de exploração

src/train.py | GridSearch, persistência, escolha do melhor modelo

src/evaluate.py | Métricas e gráficos de desempenho

src/explain.py | Feature importance + SHAP

app/streamlit_app.py | Demo (predição + análise)

scripts/explore.py | EDA + discussão no terminal (vídeo)

scripts/export_figures.py | Regenera todos os prints

Dockerfile | Ambiente reproduzível da demo

Execução: ver README.md.

10. Vídeo de demonstração (roteiro ≤ 15 min)

Checklist para gravação (YouTube ou Vimeo, público ou não listado):

1. (1–2 min) Contexto do hospital + recorte Wisconsin + disclaimer
2. (3 min) python scripts/explore.py: EDA, balanceamento, boxplots, correlação
3. (4 min) Pipeline, os três modelos, métricas (ênfase em recall) e SHAP
4. (4 min) Streamlit ao vivo: caso maligno, caso benigno, waterfall
5. (1 min) Limitações e papel do médico; link do GitHub

11. Conclusão

A Fase 1 entrega um ciclo completo de ML aplicado à saúde da mulher: exploração, pré-processamento com Pipeline, três classificadores, métricas alinhadas ao custo clínico do falso negativo, explicabilidade (importance + SHAP) e uma interface de demonstração. O artefato é uma base de suporte à decisão, não um dispositivo diagnóstico.